

T4-incertidumbre.pdf



Olmar_eps



Inteligencia Artificial



3º Grado en Ingeniería Informática



**Escuela Politécnica Superior
Universidad Autónoma de Madrid**

BBVA**1/6**

Este número es indicativo del riesgo del producto, siendo 1/6 indicativo de menor riesgo y 6/6 de mayor riesgo.

BBVA está adherido al Fondo de Garantía de Depósitos de Entidades de Crédito de España. La cantidad máxima garantizada es de 100.000 euros por la totalidad de los depósitos constituidos en BBVA por persona.

Ábrete la Cuenta Online de BBVA y llévate 1 año de **Wuolah PRO**

Ventajas Cuenta Online de BBVA

0€

Sin comisión de administración o mantenimiento de cuenta.
(0 % TIN 0 % TAE)

0€

Sin comisión por emisión y mantenimiento de Tarjeta Aqua débito.

0

Sin necesidad de domiciliar nómina o recibos.

Las ventajas de **WUOLAH PRO**



Di adiós a la publi en los apuntes y en la web



Descarga carpetas completas de un tirón



Acumula tickets para los sorteos

cómo??





1/6

Este número es indicativo del riesgo del producto, siendo 1/6 indicativo de menor riesgo y 6/6 de mayor riesgo.

BBVA está adherido al Fondo de Garantía de Depósitos de Entidades de Crédito de España. La cantidad máxima garantizada es de 100.000 euros por la totalidad de los depósitos constituidos en BBVA por persona.

ventajas

PRO



Di adiós a la publi en los apuntes y en la web



Acumula tickets para los sorteos



Descarga carpetas completas

estudia sin publi
WUOLAH PRO

Tema 4: INCERTIDUMBRE

4.1. FORMALIZACIÓN de INCERTIDUMBRE mediante PROBABILIDAD

- Ley de Probabilidad Total:

$$P(B) = \sum_{i=1}^n P(B, A=a_i) = \sum_{i=1}^n P(B|A=a_i) P(A=a_i)$$

- Probabilidad Condicional

$$P(A|B) = \frac{P(A, B)}{P(B)}$$

- Regla de la Suma

$$P(A) + P(\bar{A}) = 1 \quad P(A|I) + P(\bar{A}|I) = 1$$

- Regla del producto

$$P(A, B) = P(A|B) P(B) = P(B|A) P(A) \quad \boxed{P(A, B|I) = P(B|A, I) P(A|I)}$$

- Regla de Bayes


$$P(A|B) = \frac{\overset{\text{verosimilitud hipótesis dado los datos}}{P(B|A)} \cdot \overset{\text{prob. PRIORI}}{P(A)}}{\underset{\text{prob. POSTERIORI}}{P(B)}} \quad \boxed{P(A|B, I) = \frac{P(B|A, I) P(A|I)}{P(B|I)}}$$

- Independencia

A y B independientes si $P(A, B) = P(A|B) P(B) = P(A) \cdot P(B)$

A es condicionalmente independiente de B dado C si:

$$P(A|B, C) = P(A|C) \quad \Leftrightarrow \quad P(A, B|C) = P(A|C) P(B|C)$$



4.2. TEOREMA de BAYES en IA

→ PRIOR: probabilidad a priori de la hipótesis H .

Probabilidad de la hipótesis, antes de observar los datos

$$P(H) \longrightarrow \sum_H P(H) = 1$$

→ POSTERIOR: probabilidad a posteriori de la hipótesis H .

Probabilidad de la hipótesis, después de observar los datos.

$$P(H|D) \longrightarrow \sum_H P(H|D) = 1$$

Difícil de estimar
(condicionado a D)

→ VEROSIMILITUD: de la hipótesis dado los datos.

$$P(D|H)$$

Más confiables que las posteriores

→ EVIDENCIA: de los datos.

Es independiente de la hipótesis y funciona como un factor de normalización.

$$P(D) = \sum_H P(D|H) P(H) \rightsquigarrow \text{cte de normalización}$$

■ INFERENCIA a partir de los DATOS (seleccionando hipótesis)

↳ PRIOR: $H_{\text{prior}}^* = \underset{H}{\operatorname{argmax}} P(H)$ (ignora información de D)

↳ ML: $H_{\text{ML}}^* = \underset{H}{\operatorname{argmax}} P(D|H)$ (no usa información de los priors)
max. → asigna la clase
veros. → que maximiza la veros.
≡ prior uniforme

mira tabla
y filtra
por (10)

↳ MAP: $H_{\text{MAP}}^* = \underset{H}{\operatorname{argmax}} P(H|D) \rightarrow$ Bayes es óptimo \rightarrow minimiza el error
max. → asigna la clase
posterior → que maximiza prob. post.

↳ INFERENCIA BAYESIANA: $E(P(H)) = \sum_H P(H) P(H|D) \rightarrow$ promedia sobre hipótesis con probabilidades

* Si las estimaciones de posteriores son fiables, MAP es mejor

* Seleccionar ML puede ser ventajoso cuando los priors son desconocidos.

* $H_{\text{ML}}^* = H_{\text{MAP}}^*$ si los priors de todas las hipótesis son iguales


■ NAÏVE BAYES

NB asume que los atributos son independientes condicionados a la clase.

$$P(X|C) = P(x_1|C)P(x_2|C)\dots P(x_D|C)$$

Teorema de Bayes

$$P(C|X) = \frac{P(X|C) \cdot P(C)}{P(X)} = \frac{P(x_1|C)P(x_2|C)\dots P(x_D|C)}{P(X)}$$



- Ⓥ: Entrenamiento y precisión rápidos
- ⓓ: Las estimaciones de probabilidad no son confiables

■ ESTIMACIÓN de PROBABILIDADES

Las estimaciones de frecuencia de probabilidades pueden no ser fiables, especialmente cuando las muestras son pequeñas (términos ≈ 0)

⇒ ESTIMADOR de LAPLACE


- Evita estimaciones nulas para las probabilidades
- Estimaciones más robustas
- Asintóticamente pequeño

$$P_i = \frac{n_i + \frac{N}{K}}{n_{\text{total}} + N} \xrightarrow[\text{ejemplo práctico}]{\text{típicamente } N=K} P_i = \frac{n_i + 1}{n_{\text{total}} + N}$$

4.3. RED BAYESIANA

$$P(\text{nodo} | \text{padres}(\text{nodo})) \Rightarrow P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{padres}(x_i))$$

ej:



$$P(x_1 | x_2, x_3, x_4) \cdot P(x_2 | x_3, x_4) \cdot P(x_3 | x_4) \cdot P(x_4)$$

- $x_2 \rightarrow x_1$ significa que x_2 está entre las variables en las que x_1 es condicionada.
- Si no pongo relación entre dos nodos ($x_3 \cdots x_1$) significa que x_3 es cond. indep de x_1 , dados x_2 y x_4 .